

UNIVERSIDADE FEDERAL DE ALFENAS - UNIFAL-MG

WELLINTON OLIVEIRA SANTOS

**MODELAGEM PREDITIVA DE SINISTROS AGRÍCOLAS:
UMA ARQUITETURA DE APRENDIZADO DE MÁQUINA SOBRE DADOS DO
SISSER (2016-2025)**

VARGINHA-MG

2026

WELLINTON OLIVEIRA SANTOS

**MODELAGEM PREDITIVA DE SINISTROS AGRÍCOLAS:
UMA ARQUITETURA DE APRENDIZADO DE MÁQUINA SOBRE DADOS DO
SISSER (2016-2025)**

Trabalho de Conclusão do Programa Integrado de Pesquisa, Ensino e Extensão (PIEPEX) apresentado como parte dos requisitos para obtenção do título de Bacharel em Ciência e Economia pela Universidade Federal de Alfenas.

Orientadora: Patrícia de Siqueira Ramos

VARGINHA-MG

2026

WELLINTON OLIVEIRA SANTOS

**MODELAGEM PREDITIVA DE SINISTROS AGRÍCOLAS:
UMA ARQUITETURA DE APRENDIZADO DE MÁQUINA SOBRE DADOS DO
SISSER (2016-2025)**

A Presidente da banca examinadora abaixo assina a aprovação do Trabalho de Conclusão do PIEPEX, apresentado como parte dos requisitos para obtenção do grau de Bacharel em Ciência e Economia pela Universidade Federal de Alfenas.

Aprovado em: 03 de junho de 2026

Prof^ª. Dr^ª. Patrícia de Siqueira Ramos
Universidade Federal de Alfenas

Assinatura:



Documento assinado digitalmente

PATRICIA DE SIQUEIRA RAMOS

Data: 22/06/2026 18:11:43-0300

Verifique em <https://validar.iti.gov.br>

Prof. Dr. Leandro Ferreira
Universidade Federal de Alfenas

Assinatura:

Prof. Me. Walef Machado de Mendonça
Universidade Federal de Alfenas

Assinatura:

RESUMO

O agronegócio brasileiro respondeu por 23,5% do PIB nacional em 2024, e erros na estimação da probabilidade de sinistro em carteiras de seguro rural afetam tanto as provisões técnicas das seguradoras quanto o equilíbrio fiscal do Programa de Subvenção ao Prêmio do Seguro Rural (PSR). Dessa forma, o presente artigo desenvolve e avalia um *pipeline* de classificação binária supervisionada para predição de sinistros no PSR, com base em dados individuais de apólice do SISSER/MAPA cobrindo o período de 2016 a 2025, implementado na plataforma Databricks com Arquitetura Medalhão, *Feature Store* com semântica *point-in-time* em seis tabelas de agregação histórica e validação *out-of-time* com corte em janeiro de 2025. A base processada compreende 1.078.274 apólices encerradas, considerando corte em 31 de dezembro de 2025, com taxa de sinistro de 27,5%. A análise descritiva revelou concentração de 65% dos contratos na Região Sul, também a de maior sinistralidade (30,5%), com alta volatilidade interanual, com taxas abaixo de 20% entre 2016 e 2020 e acima de 50% em 2021. Entre os quatro algoritmos avaliados (Árvore de Decisão, Floresta Aleatória, AdaBoost e XGBoost), o XGBoost foi selecionado como modelo campeão com AUC-ROC de 0,893, AUC-PR de 0,794, KS de 0,626 e Lift cumulativo a 10% de 3,195 no conjunto de teste, superando em 26 pontos percentuais o melhor resultado reportado na literatura sobre a mesma fonte de dados.

Palavras-chave: seguro rural; predição de sinistros; aprendizado de máquina; arquitetura medalhão; *Feature Store*.

ABSTRACT

Brazilian agribusiness accounted for 23.5% of national GDP in 2024. In rural insurance portfolios, inaccurate claim probability estimates affect insurer technical provisions and the fiscal balance of Brazil's Rural Insurance Premium Subsidy Program (PSR). This paper develops and evaluates a supervised binary classification pipeline for claim prediction under the PSR, using individual policy records from SISSER/MAPA covering 2016 to 2025. The pipeline was implemented on Databricks under a Medallion Architecture with a six-table Feature Store built on point-in-time aggregation semantics; out-of-time validation used a temporal cutoff of January 2025. The processed dataset comprises 1,078,274 closed policies, considering the cut-off date of December 31, 2025, with an overall claim rate of 27.5%. Descriptive analysis shows that 65% of contracts are concentrated in the South region, which also records the highest claim rate (30.5%) and marked interannual volatility: rates remained below 20% from 2016 to 2020 and exceeded 50% in 2021. Four tree-based classifiers were assessed (Decision Tree, Random Forest, AdaBoost and XGBoost), with XGBoost selected as the champion model. On the test set, it achieved an AUC-ROC of 0.893, AUC-PR of 0.794, KS of 0.626, and a cumulative Lift at 10% of 3.195, a result 26 percentage points above the best AUC-ROC reported in the literature on the same data source.

Keywords: rural insurance; claim prediction; machine learning; medallion architecture; Feature Store.

SUMÁRIO

1 INTRODUÇÃO.....	6
2 REFERENCIAL TEÓRICO.....	8
2.1 SEGURO RURAL NO BRASIL.....	8
2.2 APRENDIZADO DE MÁQUINA SUPERVISIONADO E A PREVISÃO DE SINISTROS.....	9
2.2.1 Árvores de Decisão e Ensembles.....	10
2.2.2 XGBoost.....	12
2.2.3 Desbalanceamento de classes.....	13
2.2.4 Métricas de avaliação.....	15
3 METODOLOGIA.....	17
3.1 FONTE E CARACTERIZAÇÃO DOS DADOS.....	17
3.2 PROCESSAMENTO DOS DADOS E ARQUITETURA MEDALHÃO.....	18
3.3 CRIAÇÃO DAS VARIÁVEIS PREDITORAS E FEATURE STORE.....	20
3.4 ESPECIFICAÇÃO DO PROBLEMA E MODELAGEM.....	22
4 RESULTADOS E DISCUSSÕES.....	25
4.1 ANÁLISE DESCRITIVA.....	25
4.2 COMPARATIVO DOS MODELOS.....	27
4.3 AVALIAÇÃO DO MODELO CAMPEÃO.....	28
4.4 IMPORTÂNCIA DAS VARIÁVEIS.....	30
5 CONSIDERAÇÕES FINAIS.....	33
REFERÊNCIAS.....	35

1 INTRODUÇÃO

O agronegócio brasileiro constitui um dos pilares estruturais da economia nacional, com participação importante na formação e composição do Produto Interno Bruto (PIB) e protagonismo nas exportações de *commodities* agrícolas (MAPA, 2026). Esses resultados, no entanto, estão sujeitos a um conjunto de riscos climáticos cujo caráter sistêmico distingue o setor dos demais ramos do mercado segurador. Eventos como secas, geadas e granizo afetam simultaneamente diversas propriedades de uma mesma região, de modo que a probabilidade de sinistro não é independente entre os segurados (Mota; Miquelluti; Ozaki, 2020; Ozaki, 2008). As consequências se propagam além do campo: instabilidades na sinistralidade repercutem sobre as provisões técnicas das seguradoras, cujas estimativas insuficientes expõem as empresas ao risco de insolvência (Mota; Miquelluti; Ozaki, 2020), e sobre o equilíbrio fiscal dos programas de subvenção governamental, historicamente marcados por déficits associados à precificação inadequada do risco (Ozaki, 2008). Nesse contexto, a capacidade de antecipar a ocorrência de sinistros nas apólices de seguro rural não constitui apenas uma questão atuarial, mas uma condição necessária para a sustentabilidade econômica de todo o sistema (Pijl, 2017).

O mercado de seguro rural no Brasil percorreu uma trajetória institucional marcada por tentativas frustradas de operação pública e por um redesenho estrutural que culminou, em 2003, na criação do Programa de Subvenção ao Prêmio do Seguro Rural (PSR). Dessa forma, o PSR transferiu a subscrição do risco para o mercado privado ao mesmo tempo em que reduziu o custo das apólices para o produtor por meio da subvenção direta sobre o prêmio, expandindo o volume de contratos e a importância segurada ao longo das décadas seguintes (Ozaki, 2008). Essa arquitetura, contudo, introduz uma forma de interdependência fiscal: erros sistemáticos na estimação do risco e na precificação das apólices exercem pressão simultânea sobre a solvência das seguradoras e sobre o Tesouro Nacional, que sustenta o subsídio. A qualidade da estimativa de probabilidade de sinistro ocupa, portanto, posição central tanto na gestão das carteiras privadas quanto na previsibilidade do gasto público com o programa.

A literatura aplicada à predição de sinistros agrícolas no Brasil ainda é incipiente. Mota, Miquelluti e Ozaki (2020), em estudo de referência para a predição de sinistros no PSR, avaliaram algoritmos de aprendizado de máquina sobre dados do PSR para o período de 2006 a 2017 e documentaram capacidade preditiva limitada, atribuída, sobretudo, ao nível de agregação municipal dos dados disponíveis, insuficiente para capturar a heterogeneidade do

risco em nível de apólice individual. É essa limitação que o presente trabalho busca superar. A disponibilização pública dos dados do Sistema de Subvenção Econômica ao Prêmio do Seguro Rural (SISSER) pelo Ministério da Agricultura, Pecuária e Abastecimento, cobrindo apólices contratadas de 2016 a 2025 (BRASIL, 2026), cria a condição técnica necessária para avançar sobre tal limitação.

Dessa forma, o presente estudo tem por objetivo desenvolver, avaliar e documentar um *pipeline* completo de predição de sinistros no PSR, abrangendo desde a ingestão dos dados brutos do SISSER até o registro do modelo em uma plataforma de MLOps com rastreabilidade de parâmetros, métricas e artefatos. A solução opera sobre dados individuais de apólice em nível de contrato, organizados por meio da Arquitetura Medalhão, com construção de variáveis sob a semântica *point-in-time* e validação temporal *out-of-time*.

Por fim, o trabalho está organizado em cinco seções, incluindo essa introdução. A seção 2 apresenta o referencial teórico, abordando o mercado de seguro rural no Brasil e os fundamentos de aprendizado de máquina supervisionado aplicado à predição de sinistros. A seção 3 descreve a fonte de dados, o *pipeline* de processamento e a estratégia de modelagem adotada. A seção 4 apresenta os resultados, organizados em análise descritiva da base de dados, uma comparação entre os algoritmos, a avaliação do modelo campeão e a importância das variáveis na capacidade preditiva do modelo. A seção 5 sintetiza os principais achados, discute as limitações e indica direções para pesquisas futuras.

2 REFERENCIAL TEÓRICO

2.1 SEGURO RURAL NO BRASIL

O agronegócio brasileiro ocupa uma posição estrutural relevante para a economia nacional. De acordo com dados do Ministério da Agricultura e Pecuária (MAPA, 2026), o Produto Interno Bruto do agronegócio somou R\$ 2.763,65 bilhões em 2024, correspondendo a 23,5% do PIB nacional, com projeção de expansão para R\$ 3.789,53 bilhões em 2025. No plano externo, apenas no acumulado de janeiro a fevereiro de 2026, as exportações do agronegócio totalizaram US\$ 22,73 bilhões, com o Brasil ocupando primeiro lugar mundial nas exportações de açúcar, café, suco de laranja, soja em grão, carne bovina e carne de frango (MAPA, 2026). Essa escala produtiva e comercial confere à gestão de riscos agrícolas implicações que vão além da esfera das seguradoras e dos produtores individualmente: instabilidades severas na sinistralidade propagam-se pela cadeia de financiamento, pelo equilíbrio fiscal do programa de subvenção federal e, em última instância, pela renda de milhões de produtores rurais.

O risco agrícola distingue-se dos demais ramos do mercado segurador pelo seu caráter sistêmico. Eventos climáticos como seca, granizo, geadas e chuvas excessivas afetam simultaneamente produtores de uma mesma região, violando o pressuposto de independência de sinistros que sustenta o cálculo atuarial clássico. Dados do PSR para o período de 2006 a 2017 ilustram esse padrão com nitidez: a seca foi a causa do maior volume financeiro de indenizações, com R\$ 1,57 bilhão distribuídos em 6.567 ocorrências; o granizo respondeu por R\$ 1,06 bilhão em 7.570 ocorrências. Fenômenos climáticos de escala global aprofundam essa interdependência. O El Niño tende a favorecer culturas como o milho na Região Sul, enquanto o La Niña produz o efeito contrário, com impactos que revertem de forma assimétrica em outras regiões do país (Mota; Miquelluti; Ozaki, 2020). Como a carteira do PSR é geograficamente concentrada na região Sul, sendo responsável por mais de 80% dos eventos de sinistros nas principais culturas, choques climáticos de escala regional produzem impactos desproporcionais sobre o programa como um todo (Mota; Miquelluti; Ozaki, 2020).

Esse perfil de risco sistêmico, concentrado geograficamente e amplificado por ciclos climáticos globais, é precisamente o que o arcabouço regulatório do seguro rural precisa administrar. O Programa de Subvenção ao Prêmio do Seguro Rural (PSR), instituído pela Lei nº 10.823 de 2003, estabeleceu o modelo vigente. Por meio dele, o governo concede subvenção direta sobre o prêmio das apólices contratadas no mercado privado, enquanto o

produtor paga apenas a parcela $(1 - s) \times P$ (sendo s o percentual de subsídio e P o prêmio integral), sem que o governo assuma diretamente o risco técnico das carteiras (Ozaki, 2008). A importância segurada saltou de R\$ 1,46 bilhão em 2006 para aproximadamente R\$ 10,59 bilhões em 2018 e a carteira chegou a cobrir 57 culturas. Ainda assim, a distribuição dos contratos permanece altamente concentrada: apenas soja, milho, maçã e trigo respondem por mais de 81% do volume total (Mota; Miquelluti; Ozaki, 2020). Essa concentração, combinada com a ausência de metodologias adequadas de precificação e a escassez de séries históricas, constitui o principal entrave técnico ao desenvolvimento do mercado (Ozaki, 2008). A disponibilização dos dados públicos do SISSER pelo MAPA, cobrindo apólices de 2016 a 2025, cria as condições para suprir parte dessa lacuna por meio de modelagem preditiva baseada em aprendizado de máquina.

2.2 APRENDIZADO DE MÁQUINA SUPERVISIONADO E A PREVISÃO DE SINISTROS

O aprendizado de máquina supervisionado designa o conjunto de algoritmos que, a partir de exemplos históricos cujo resultado já é conhecido, aprendem a reconhecer padrões e a produzir previsões para observações novas. Formalmente, dado um conjunto de treinamento $D = \{(x_1, y_1), \dots, (x_n, y_n)\}$, em que x_i representa o vetor de características da i -ésima observação e y_i o rótulo correspondente, o objetivo é estimar uma função $f: X \rightarrow Y$ que generalize o padrão aprendido para valores de entrada não observados durante o treinamento (Dreiseitl; Ohno-Machado, 2002). No presente estudo, o problema é de classificação binária: o rótulo assume valor 1 quando a apólice resultou em sinistro e 0 caso contrário.

A literatura aplicada ao mercado segurador documenta uma expansão consistente dessas abordagens. Mota, Miquelluti e Ozaki (2020) testaram Florestas Aleatórias (*Random Forest*), Máquinas de Vetores de Suporte (*Support Vector Machines*) e k-Vizinhos Mais Próximos (*k-Nearest Neighbors*) sobre dados do PSR entre 2006 e 2017, verificando que todos os métodos apresentaram capacidade preditiva limitada, atribuída pelos autores, sobretudo, devido à granularidade municipal dos dados, insuficiente para capturar a variabilidade produtiva em nível de apólice. Esse diagnóstico tem implicação metodológica direta para o presente trabalho: a etapa de construção de variáveis com janelas temporais de agregação histórica por município, cultura e seguradora é o mecanismo proposto para superar essa limitação. Bärthel e Krummacker (2020) e Ejayi et al. (2022) reforçam, em contextos

distintos, que a qualidade das variáveis é o principal fator de diferenciação entre classificadores.

As técnicas de aprendizado supervisionado podem ser organizadas em diferentes famílias segundo sua lógica de aprendizagem: modelos lineares, como a regressão logística; algoritmos de vizinhança, como o k-Vizinhos Mais Próximos (*k-Nearest Neighbors*); redes neurais artificiais; e métodos baseados em árvores de decisão, incluindo abordagens individuais e de conjunto (*ensemble*) (Mahesh, 2019). Cada família difere não apenas na estrutura matemática, mas também no comportamento frente a dados desbalanceados, variáveis com interações não lineares e observações com valores ausentes. Este artigo concentra-se nos métodos baseados em árvores e em suas extensões de *ensemble* como, Árvores de Decisão, Florestas Aleatórias (*Random Forest*), AdaBoost e XGBoost, por serem os mais adequados a dados tabulares com essas características e pelos resultados consistentemente superiores que apresentam em problemas análogos na literatura de seguros (Bärtil; Krummaker, 2020). As seções 2.2.1 e 2.2.2 detalham, respectivamente, os fundamentos das árvores e dos métodos de *ensemble*, com atenção especial ao XGBoost, algoritmo selecionado como modelo campeão neste estudo.

2.2.1 Árvores de Decisão e *Ensembles*


A árvore de decisão particiona recursivamente o espaço de características, também conhecido como *features* ou variáveis, por meio de regras binárias, guiada por critérios de impureza, como o índice de Gini ou entropia informacional, que medem o grau de mistura entre classes resultante de cada divisão (Mahesh, 2019). Sua principal vantagem é interpretabilidade direta frente a outros métodos: o caminho da raiz à folha corresponde a uma sequência de condições verificáveis sobre as variáveis do modelo, o que torna o algoritmo comunicável às equipes de negócio (Bärtil; Krummaker, 2020). Entretanto, sua principal limitação é a instabilidade, isto é, pequenas variações nos dados de treinamento podem produzir estruturas de partição completamente diferentes, o que restringe sua capacidade de generalização quando utilizada de forma isolada.

A Floresta Aleatória (*Random Forest*) contorna essa instabilidade por meio de dois mecanismos de aleatorização simultâneos: cada árvore é treinada sobre uma subamostra com reposição do conjunto de treinamento, e em cada nó a busca pela melhor divisão considera apenas um subconjunto sorteado das variáveis disponíveis (Breiman, 2001). Assim, a predição final é a média das probabilidades produzidas por todas as árvores. Dessa forma,

essa dupla aleatorização reduz a correlação entre os estimadores individuais, diminuindo a variância do modelo agregado sem elevar proporcionalmente o viés. O AdaBoost (Freund; Schapire, 1997), por sua vez, adota uma lógica sequencial: treina modelos fracos iterativamente, concentrando o esforço de cada iteração nos exemplos classificados incorretamente na rodada anterior. A predição final, por sua vez, pondera os modelos individuais pela sua acurácia durante o treinamento. No presente estudo, o AdaBoost serve como *baseline* de comparação ao lado da árvore de decisão isolada e da Floresta Aleatória.

A Figura 1 apresenta os dois mecanismos de *ensemble* discutidos nesta seção. No painel esquerdo, a Floresta Aleatória (*Random Forest*) constrói cada árvore sobre uma amostra com reposição distinta do conjunto original, garantindo que os estimadores sejam treinados de forma independente. A predição final resulta da votação igualitária entre todas as árvores, representada pela balança, em que cada estimador contribui com o mesmo peso na decisão coletiva (Breiman, 2001). No painel direito, o AdaBoost segue uma lógica sequencial: cada novo aprendiz é treinado sobre o mesmo conjunto de dados, com os pesos das observações ajustados conforme o desempenho da iteração anterior. Dessa forma, os exemplos mal classificados recebem peso crescente, visível nos círculos de tamanho progressivamente maior, de modo que os aprendizes subsequentes concentram o esforço nos casos mais difíceis. Por fim, a combinação final pondera cada estimador por sua taxa de acerto durante o treinamento, o que explica as setas de espessura variável que convergem para o resultado (Freund; Schapire, 1997).

Figura 1 - Floresta Aleatória (a) vs AdaBoost (b)



Fonte: elaboração própria, com base em Breiman (2001) e Freund e Schapire (1997).

2.2.2 XGBoost

O XGBoost (*Extreme Gradient Boosting*), proposto por Chen e Guestrin (2016), é uma implementação de *gradient boosting* que constrói sequencialmente um conjunto de árvores de decisão, em que cada árvore adicionada minimiza o erro residual acumulado pelas anteriores. Sua distinção central em relação a implementações anteriores está na função objetivo regularizada: além da função de perda convencional, o algoritmo penaliza explicitamente a complexidade de cada árvore adicionada, controlando o número de folhas e a magnitude dos seus pesos. Esse mecanismo reduz o overfitting, isto é, a tendência do modelo de memorizar padrões dos dados de treinamento em vez de generalizá-los, de forma integrada ao próprio processo de aprendizado (Chen; Guestrin, 2016). A otimização é conduzida por aproximação de segunda ordem da função de perda, o que acelera a convergência e permite derivar analiticamente os pesos ótimos de cada folha.


Três propriedades do XGBoost têm relevância direta para o problema de seguros rurais:

1. Tratamento nativo de dados esparsos. Durante o treinamento, o algoritmo aprende a direção ótima para observações com valor ausente, sem exigir imputação prévia, o que preserva o significado informacional das ausências, pois em bases com cobertura histórica irregular, um valor ausente indica falta de histórico, não risco nulo.
2. Parâmetro *scale_pos_weight*. Esse parâmetro atribui peso diferenciado à classe positiva durante o treinamento, deslocando a fronteira de decisão em direção aos sinistros sem recorrer à técnicas de reamostragem.
3. Hiperparâmetros para ajuste fino (*fine-tuning*). Parâmetros como taxa de aprendizado (*learning_rate*), profundidade máxima das árvores (*max_depth*), subamostragem por linha (*subsample*) e por coluna (*colsample_bytree*) permitem um ajuste fino ao problema em questão (Chen; Guestrin, 2016; XGBoost, 2026).

A Figura 2 sintetiza o funcionamento do XGBoost. Em cada iteração, o algoritmo recebe o erro residual da etapa anterior, indicado pelo símbolo Δ em laranja, e ajusta uma nova árvore para corrigi-lo. As parábolas sobrepostas a cada árvore representam a aproximação de segunda ordem da função de perda, mecanismo que permite calcular os pesos ótimos de cada folha sem uma varredura exaustiva do espaço de parâmetros. O painel direito de cada iteração mostra a poda decorrente do termo de regularização: galhos cortados pelas tesouras correspondem a divisões cuja contribuição não justifica o aumento de complexidade penalizado pela função objetivo. As árvores ficam progressivamente menores ao longo das

iterações, efeito do *shrinkage* ou encolhimento, que reduz a influência de cada estimador individual e preserva espaço de ajuste para as etapas seguintes. Ao final, o símbolo Σ indica que a predição do modelo é a soma das contribuições de todas as árvores, e a curva na base da figura representa a distribuição dos escores preditos pelo modelo, isto é, os valores entre 0 e 1 que estimam a probabilidade de sinistro de cada apólice, obtidos após a transformação da soma das contribuições de todas as árvores (Chen; Guestrin, 2016).

Figura 2 - Funcionamento do XGBoost



Fonte: elaboração própria, com base em Chen e Guestrin (2016)

2.2.3 Desbalanceamento de classes

O desbalanceamento de classes ocorre quando, em um problema de classificação binária, uma das categorias da variável resposta é substancialmente mais frequente do que a outra. Essa assimetria é comum em aplicações práticas, como diagnósticos médicos de

doenças raras, detecção de fraudes e, no contexto deste artigo, ocorrências de sinistros em carteiras de seguros, e compromete diretamente o processo de aprendizagem do modelo. Dessa forma, como a maioria dos classificadores otimiza funções de acurácia global, o algoritmo aprende que prever sistematicamente a categoria majoritária minimiza o erro agregado, ainda que produza desempenho nulo sobre a classe de interesse (Menardi; Torelli, 2014; Weiss; McCarthy; Zabar, 2007).

Em carteiras de seguro rural, sinistros são eventos relativamente raros. Nos dados do PSR analisados por Mota, Miquelluti e Ozaki (2020), a proporção entre classes era de aproximadamente 76,3% para apólices sem sinistro e 23,7% para apólices com sinistro, um desequilíbrio que afeta diretamente o processo de treinamento. Como enfatizam Menardi e Torelli (2014), quando as classes não são perfeitamente separáveis, o não tratamento do desequilíbrio produz consequências significativas tanto na estimação do modelo quanto na avaliação de sua precisão.

A literatura propõe três grupos principais de estratégias para contornar o problema. O primeiro atua sobre os dados: a sobreamostragem replica observações da classe minoritária, ao passo que, a subamostragem reduz o volume da majoritária. Weiss, McCarthy e Zabar (2007) demonstraram que ambas as abordagens produzem ganhos equivalentes de desempenho em árvores de decisão. O segundo grupo opera no nível do aprendizado, atribuindo pesos assimétricos aos erros de classificação para forçar o modelo a penalizar mais os erros sobre a classe rara, estratégia implementada por meio do parâmetro *scale_pos_weight* no XGBoost. Por fim, o terceiro consiste no ajuste do limiar de decisão, isto é, em vez de classificar como sinistro apenas observações com probabilidade superior a 0,5, o limiar é deslocado para tornar mais difícil que exemplos da classe minoritária sejam incorretamente descartados (Menardi; Torelli, 2014). No presente estudo, adotou-se a estratégia de ponderação de classes, implementada via *scale_pos_weight* no XGBoost.

A preferência em relação à reamostragem decorre de dois fatores:

1. A ponderação não altera a distribuição dos dados de treinamento, preservando os padrões de correlação entre as variáveis.
2. Os erros sobre a classe rara são penalizados diretamente na função de perda, sem introduzir observações sintéticas que poderiam gerar sobreajuste no modelo.

2.2.4 Métricas de avaliação

A avaliação de classificadores binários parte de uma estrutura tabular denominada matriz de confusão, que cruza os valores reais e os previstos pelo modelo. Conforme apresentado no Quadro 1, os resultados são organizados em quatro categorias: verdadeiros positivos (VP), quando o modelo identifica corretamente uma apólice com sinistro; verdadeiros negativos (VN), quando identifica corretamente uma apólice sem sinistro; falsos positivos (FP), quando prevê sinistro em apólices que não tiveram; e falsos negativos (FN), quando deixa de identificar apólices que de fato foram sinistradas (Fawcett, 2006; Mota; Miquelluti; Ozaki, 2020). A partir desses quatro elementos derivam-se as métricas de desempenho utilizadas neste trabalho.

Quadro 1 - Matriz de Confusão

Classe	Atual Positivo	Atual Negativo
Predição Positiva	Verdadeiro Positivo (VP)	Falso Positivo (FP)
Predição Negativa	Falso Negativo (FN)	Verdadeiro Negativo (VN)

Fonte: Elaboração própria com base em Fawcett (2006) e Mota, Miquelluti e Ozaki (2020)

A acurácia corresponde à proporção de classificações corretas sobre o total de observações (Mota; Miquelluti; Ozaki, 2020):

$$Acurácia = \frac{VP + VN}{VP + VN + FP + FN} . \quad (1)$$

Em conjuntos de classes desbalanceadas, porém, a acurácia pode ser elevada mesmo quando o modelo ignora a classe minoritária, o que a torna insuficiente como critério único de avaliação (Fawcett, 2006). Assim, a precisão (*precision*) mede a proporção de predições positivas que correspondem a sinistros reais:

$$Precisão = \frac{VP}{VP + FP} , \quad (2)$$

O *recall*, também chamado de sensibilidade, captura a fração dos sinistros efetivos que o modelo detectou, sendo também referida como a taxa de captura do modelo (Fawcett, 2006; Pijl, 2017):

$$Recall = \frac{VP}{VP + FN} , \quad (3)$$

Para problemas com distribuição assimétrica de classes, a curva ROC (*Receiver Operating Characteristic*) e sua área correspondente, a AUC-ROC, são critérios de avaliação amplamente adotados. A curva ROC plota a taxa de verdadeiros positivos contra falsos

positivos ao longo de diferentes limiares de decisão, avaliando o poder discriminatório do modelo sem depender da proporção entre classes. A AUC-ROC resume esse desempenho em um valor entre 0,5, equivalente a uma classificação aleatória, e 1,0, interpretado como a probabilidade de o modelo atribuir escore mais alto a uma apólice com sinistro do que a uma sem sinistro, escolhidas aleatoriamente (Fawcett, 2006; Mota; Miquelluti; Ozaki, 2020).

Complementar à curva ROC, a curva de Precisão-*Recall* (PR) plota a precisão contra o *recall* ao longo dos diferentes limiares de decisão e sua área correspondente, a AUC-PR, resume esse desempenho em um único valor. Enquanto a curva ROC é insensível a mudanças na proporção das classes, a curva PR é diretamente afetada por esse desequilíbrio: ao aumentar os casos negativos, a curva ROC do classificador permanece estável, ao passo que a curva PR se altera substancialmente (Fawcett, 2006). Essa sensibilidade torna a AUC-PR especialmente útil em cenários de forte desbalanceamento de classes (Huyen, 2022; Menardi; Torelli, 2014). Em carteiras de seguro rural, dado que a classe positiva é minoritária e os custos dos erros são assimétricos (deixar de identificar uma apólice sinistrada compromete o dimensionamento das provisões técnicas, ao passo que, classificar erroneamente uma apólice saudável como de risco representa apenas precaução excessiva), a curva PR expõe com mais clareza o quanto o modelo é capaz de manter precisão elevada à medida que aumenta a cobertura dos sinistros reais.

Além das métricas derivadas das curvas ROC e PR, este artigo adota a estatística KS e o Lift cumulativo a 10%. O KS mede a diferença máxima entre as funções de distribuição acumulada dos escores das apólices com sinistro e sem sinistro. Na prática, um KS de 0,626 significa que, no ponto de maior separação, a taxa cumulativa de sinistros identificados supera a de não-sinistros em 62,6 pontos percentuais. O Lift cumulativo a 10%, por sua vez, traduz esse desempenho em termos operacionais: um Lift de 3,19 indica que, ao priorizar os 10% de apólices com maior escore, a proporção de sinistros capturados é 3,19 vezes superior à de uma seleção aleatória de mesmo tamanho (Rezac; Rezac, 2011). Consideradas em conjunto, as quatro métricas são complementares, isto é, AUC-ROC e AUC-PR capturam o poder discriminatório global, KS localiza o ponto de separação máxima e Lift quantifica o ganho operacional em uma fração da carteira. O critério de seleção entre os modelos, com AUC-ROC como métrica primária, é detalhado na Seção 3.4.

3 METODOLOGIA

3.1 FONTE E CARACTERIZAÇÃO DOS DADOS

Os dados utilizados neste estudo foram extraídos do Sistema de Subvenção Econômica ao Prêmio do Seguro Rural (SISSER), disponibilizado publicamente pelo Ministério da Agricultura, Pecuária e Abastecimento (MAPA) por meio do Programa de Subvenção ao Prêmio do Seguro Rural (PSR). O SISSER constitui o repositório oficial de apólices rurais subsidiadas pelo governo federal, consolidando informações declaradas pelas seguradoras participantes do PSR a cada ciclo de contratação. A base cobre o período de 2016 a 2025, abrangendo culturas anuais, perenes, florestas, aquicultura e pecuária em todos os estados brasileiros. Para o presente estudo, foram utilizados dois arquivos disponibilizados pelo MAPA: o arquivo histórico consolidado de 2016 a 2024 e o arquivo parcial de 2025, que registra apólices contratadas até agosto do mesmo ano.


Nessa perspectiva, é válido ressaltar que a mesma fonte de dados foi utilizada por Mota, Miquelluti e Ozaki (2020) em estudo comparativo de algoritmos de aprendizado de máquina para a predição de sinistros agrícolas no Brasil, o que coloca o presente trabalho em continuidade direta com aquela contribuição. A base processada, após as transformações descritas na seção seguinte, resultou em 1.094.697 registros e 27 variáveis na camada *silver*. Além disso, a variável resposta é *flSinistro*, indicador binário derivado da coluna *evento* disponível nos arquivos do SISSER. Quando o campo registra qualquer ocorrência distinta de “nenhum”, seja seca, geada, granizo ou demais causas previstas na normatização do PSR, a variável recebe valor 1, ao passo que, nos contratos encerrados sem ocorrência de sinistro, recebe valor 0. Por fim, ainda é importante destacar que a proporção de apólices sinistradas na base histórica é consideravelmente inferior à das apólices sem sinistro, tendo apenas 27,5% com eventos positivos, configurando o desbalanceamento de classes característico desse domínio e discutido na literatura de aprendizado de máquina aplicada ao mercado segurador (Menardi; Torelli, 2014; Weiss; McCarthy; Zabar, 2007).

Caracterizados a fonte e os principais atributos da base, a subseção seguinte descreve como os arquivos brutos do SISSER foram transformados em insumos para a modelagem. Além disso, será apresentada a estrutura da Arquitetura Medalhão, detalhando as operações realizadas em cada camada do *pipeline* até a separação entre variáveis preditoras e desfecho.

3.2 PROCESSAMENTO DOS DADOS E ARQUITETURA MEDALHÃO

O *pipeline* de processamento foi implementado sobre a plataforma Databricks (Databricks, 2026a) com suporte de três linguagens: Python (Python, 2026), utilizado nos scripts de configuração, pré-processamento e treinamento dos modelos; PySpark, interface Python do Apache Spark (Zaharia et al., 2016), empregado nas transformações distribuídas sobre as tabelas Delta Lake; e Spark SQL, adotado na materialização das camadas e nas agregações históricas. A arquitetura de referência é a Medalhão, um padrão de organização de dados que estrutura o fluxo de transformações em camadas progressivas de qualidade, denominadas *bronze*, *silver* e *gold* (Databricks, 2026b). A premissa central do padrão é que os dados brutos não são modificados na origem, isto é, cada camada aplica transformações incrementais e delimitadas, permitindo rastreabilidade completa de qualquer ponto do *pipeline* até o arquivo original. A Figura 3 ilustra todo o processo da arquitetura, desde a ingestão dos dados, até o ponto de servi-los a partir das visualizações a nível agregado, e contendo as lógicas e métricas de negócio, na camada *gold*.

Figura 3 - Arquitetura Medalhão



Fonte: Databricks, 2026b

No presente trabalho, a camada *raw* corresponde ao volume de armazenamento onde os arquivos do SISSER são carregados sem modificação. A camada *bronze* realiza a ingestão desses arquivos para tabelas Delta Lake sem aplicar transformações de negócio, como a criação da variável resposta ou a categorização das culturas em grupos funcionais, preservando o seu conteúdo original. Seguindo, a camada *silver* concentra o tratamento


substantivo dos dados, isto é, a normalização de nomes dos municípios com base em uma tabela de correspondência construída a partir de dados do IBGE, tratamento da taxonomia das colunas para melhor referência, categorização das culturas em grupos funcionais (grãos, frutas, leguminosas, hortaliças, perenes e outros), mapeamento dos eventos preponderantes para categorias padronizadas, e exclusão de colunas de identificação pessoal e localização geográfica bruta. Nessa camada, também são derivadas as variáveis *sinistro* (indicador binário de ocorrência) e *sinistralidade* (razão entre valor de indenização e prêmio líquido pago), produzindo o conjunto final de 1.094.697 registros e 27 variáveis.

Por fim, a camada *gold* efetua a separação explícita entre as variáveis preditoras (*fs_seguro_features*) e variáveis de desfecho (*fs_seguro_labels*). Embora o treinamento do modelo opere diretamente sobre as tabelas da Feature Store, essa separação cumpre uma função de governança: ao materializar essa divisão no *Databricks*, cria-se um ponto de auditoria estável e independente do *pipeline* de modelagem. Adicionalmente, essa separação responde ao problema de *data leakage*, fenômeno que ocorre quando há o vazamento de informações associadas à variável resposta para o modelo durante o treinamento. Huyen (2022), por sua vez, descreve esse fenômeno como uma das causas mais comuns de falha silenciosa em sistemas de aprendizado de máquina em produção, isso por conta que, modelos treinados com dados contaminados podem apresentar um desempenho aparentemente elevado nos dados de teste, entretanto, demonstram uma queda expressiva na performance quando expostos a dados reais.

A Figura 4 resume o *pipeline* de tratamento de dados adotado no trabalho, organizado segundo a Arquitetura Medalhão.

Com o *pipeline* de processamento estabelecido e os dados organizados nas camadas *bronze*, *silver* e *gold*, a subseção 3.3 descreve a construção das variáveis preditoras. A abordagem adota um repositório de atributos com semântica *point-in-time*, que restringe cada observação ao conjunto de informações históricas efetivamente disponíveis antes de sua data de referência, eliminando qualquer possibilidade de contaminação entre treino e produção.

Figura 4 - Arquitetura Medalhão utilizada



Fonte: elaboração própria.

3.3 CRIAÇÃO DAS VARIÁVEIS PREDITORAS E FEATURE STORE

A construção da base de treinamento adotou a abordagem de *Feature Store*, uma infraestrutura de dados voltada especificamente para o ciclo de vida das variáveis preditoras em sistemas de aprendizado de máquina. Segundo Huyen (2022), uma *Feature Store* cumpre duas funções centrais: o armazenamento de *features* computadas de forma reutilizável entre diferentes modelos e equipes, assim como o versionamento que permite reproduzir qualquer conjunto de treino histórico com exatidão. Sculley et al. (2015) observam que, em sistemas de aprendizado de máquina em produção, apenas uma fração pequena do código total corresponde ao modelo em si, sendo toda a infraestrutura ao redor, o que inclui os *pipelines*

de ingestão, transformação e *serving* de *features*, a maior fonte de complexidade e de débito técnico acumulado.

Para este trabalho, todas as seis tabelas da *Feature Store* foram estruturadas sob o princípio do *point-in-time* (Databricks, 2026c), isto é, cada variável é calculada com base exclusivamente em apólices cujo ciclo já se encerrou antes da data de referência (*dtRef*) da apólice a ser pontuada. A data de referência, por sua vez, é definida como o primeiro dia do mês de início de vigência do contrato, operando como a âncora temporal que delimita o horizonte de informação disponível para cada observação. Dessa forma, somente apólices cujo período de vigência foi integralmente cumprido antes dessa âncora entram nas agregações históricas, garantindo que nenhuma informação de contratos ainda em aberto no momento da subscrição seja incorporada ao cálculo das *features*.

A tabela *fs_historico_municipio* captura o histórico de risco no nível geográfico por meio de taxas de sinistro, índices de severidade e volume de contratações em quatro janelas temporais: 90, 365, 730 e 1.095 dias anteriores à *dtRef*. Variáveis de abertura recente de apólices (*nrApoliciesAbertas30d*, *nrApoliciesAbertas90d*) funcionam como *proxies* de seleção adversa, sinalizando concentrações incomuns de novas contratações imediatamente antes da data de referência. A tabela *fs_risco_cultura_uf*, por sua vez, oferece um *baseline* de risco por estado e categoria de cultura, calculado em janelas de 365 e 730 dias.

A tabela *fs_apolice_financeiro* concentra as variáveis financeiras da apólice individual, com variáveis como a densidade de valor segurado por hectare (*nrDensidadeValorSegHa*), o prêmio por hectare (*nrPremioPorHa*), a razão entre produtividade segurada e estimada (*nrRazaoCoberturaProd*), a razão entre a subvenção federal e prêmio total (*nrRazaoSubvencaoPremio*) e o nível de cobertura contratado. O mês de plantio é codificado por meio dos componentes seno e cosseno da transformação cíclica $2\pi \times \frac{\text{mês}}{12}$, produzindo as variáveis *nrSinMes* e *nrCosMes*. Essa codificação é necessária porque a representação linear do mês traria dezembro e janeiro como extremos opostos da escala, distorcendo sua proximidade real no calendário, e somente a combinação dos dois componentes elimina a ambiguidade que afeta cada um quando utilizado de forma isolada (Matsumoto, 2023).

A tabela *fs_risco_seguradora_cultura* descreve o comportamento histórico de cada seguradora por categoria de cultura, capturando taxa de sinistro, severidade média e volume de apólices subscritas. A tabela *fs_anomalia_taxa* computa a taxa média de precificação e seu desvio padrão por cultura e unidade de federação, fornecendo a base para o índice

$nrAnomaliaTaxa$, calculado como a razão entre a taxa individual da apólice e a taxa média de referência. Valores de $nrAnomaliaTaxa$ significativamente acima de 1 sinalizam apólices com precificação anômala que pode indicar seleção adversa. A tabela $fs_concentracao_carteira$ mede a concentração geográfica de cada seguradora por meio do percentual de carteira em cada município e do índice Herfindahl-Hirschman (Ávila et al., 2013), utilizado como *proxy* do risco sistêmico associado a carteiras altamente concentradas em regiões com correlação climática elevada.

O Quadro 2 resume todas as tabelas integrantes da *Feature Store*.

Quadro 2 - Tabelas da *Feature Store*

Tabela	Descrição
$fs_historico_municipio$	Taxas de sinistro, severidade e volume de contratações por município em janelas de 90, 365, 730 e 1.095 dias.
$fs_risco_cultura_uf$	<i>Baseline</i> de risco por estado e categoria de cultura em janelas de 365 e 730 dias.
$fs_apolice_financeiro$	Variáveis financeiras da apólice individual: densidades por hectare, razões de cobertura e subvenção, nível de cobertura e codificação cíclica do mês de plantio.
$fs_risco_seguradora_cultura$	Taxa de sinistro, severidade média e volume de apólices por seguradora e categoria de cultura.
$fs_anomalia_taxa$	Taxa média e desvio padrão de precificação por cultura e UF.
$fs_concentracao_carteira$	Concentração geográfica da carteira de cada seguradora por município.

Fonte: elaboração própria.

3.4 ESPECIFICAÇÃO DO PROBLEMA E MODELAGEM

O problema de predição de sinistros é formulado como uma classificação binária supervisionada. Assim, dado um vetor de 57 variáveis $x \in R^{57}$, o modelo aprende uma função $f: x \rightarrow \{0, 1\}$ que aproxima a probabilidade de ocorrência de sinistro $P(flSinistro = 1 | x)$ (Dreiseitl; Ohno-Machado, 2002; Huyen, 2022). O treinamento é restrito ao subconjunto de apólices com data de referência anterior a janeiro de 2025, de modo que os contratos correspondentes ao período mais recente são reservados para avaliação posterior e, portanto, não participam de nenhuma etapa de seu treinamento.

A separação *out-of-time* (OOT) distingue-se da divisão aleatória frequentemente adotada na literatura de aprendizado de máquina aplicado a seguros. Bärthel e Krummacker (2020), em estudo comparativo de técnicas de aprendizado de máquina aplicadas ao seguro de crédito à exportação, argumentam que a divisão aleatória pode produzir resultados artificialmente otimistas. Por outro lado, em um cenário operacional, uma seguradora dispõe apenas de dados históricos para ajustar seus modelos e é avaliada em contratos genuinamente futuros. Dessa forma, a fim de simular esse processo, os autores isolaram os dados do ano mais recente de todo o ciclo de desenvolvimento e os utilizaram apenas para fins de teste. Nesse sentido, o presente estudo adota a mesma lógica: os dados de treinamento (apólices com *dtRef* menores a janeiro de 2025) são divididos em treino e teste na proporção 70/30 com estratificação pela variável resposta, proporção consistente com o que foi aplicado por Ejiyi et al. (2022), também no contexto de predição em seguros.

O pré-processamento das variáveis é organizado em três blocos. As variáveis numéricas e financeiras recebem imputação por mediana, as variáveis categóricas, por sua vez, recebem imputação pela moda seguida de *ordinal encoding* com *unknown_value* = -1, permitindo que categorias ausentes no treino, como uma seguradora que ingresse no mercado após o corte, sejam tratadas sem causar erros de execução em produção. Por fim, as variáveis cíclicas *nrSinMes* e *nrCosMes* não passam por transformação, visto que, já estão na escala $[-1, 1]$ e os modelos baseados em árvore são invariantes a escala de variáveis.


Quatro algoritmos foram avaliados como *baselines*: Árvore de Decisão, Random Forest, AdaBoost e XGBoost. A escolha de métodos baseados em árvore é sustentada pela literatura de predição de sinistros. Bärthel e Krummacker (2020) demonstraram que técnicas de *ensemble* superam regressões logísticas em cenários com dados desbalanceados e múltiplas interações não lineares entre variáveis. Chen e Guestrin (2016) documentam que o XGBoost apresenta eficiência particular em dados esparsos, condição presente nesse estudo dado que municípios sem histórico de contratação geram valores nulos em todas as variáveis das tabelas históricas da *Feature Store*.

A seleção do modelo campeão ocorre em duas etapas. Na primeira, os quatro algoritmos são treinados com configurações iniciais e ordenados pela AUC-ROC no conjunto de teste. O campeão é submetido a um ajuste de hiperparâmetros por *GridSearchCV* com validação cruzada estratificada em três partições, utilizando AUC-ROC novamente como critério de seleção (Pedregosa et al., 2011). Assim, o modelo ajustado é registrado no MLflow, plataforma de código aberto para o ciclo de vida de modelos que consolida

rastreamento de experimentos, versionamento e implantação em um único fluxo auditável (Zaharia et al., 2018), e publicado no Unity Catalog do Databricks, camada de governança centralizada que controla acesso, linhagem e versionamento de modelos e ativos de dados. As métricas de avaliação adotadas para comparação entre os modelos, AUC-ROC, AUC-PR, estatística KS e Lift cumulativo a 10%, foram conceituadas na seção 2.2.4.

A Figura 5 sintetiza o *pipeline* completo de treinamento e seleção do modelo campeão. A representação evidencia as três dimensões centrais da estratégia de modelagem adotada: a separação temporal entre os conjuntos de treinamento e validação, o processo comparativo entre algoritmos e o fluxo de registro no MLflow e publicação no Unity Catalog, com rastreabilidade completa de parâmetros, métricas e artefatos para consulta e *serving* em ambiente de produção.

Figura 5 - *Pipeline* de treinamento e seleção dos modelos




Fonte: elaboração própria

4 RESULTADOS E DISCUSSÕES

4.1 ANÁLISE DESCRITIVA

A base processada pela camada *silver* compreende 1.078.274 apólices de seguro rural com ciclo de vigência encerrado, cobrindo o período de 2016 a 2025. Nesse sentido, a Figura 6 ilustra a evolução anual do volume de contratos e da taxa de sinistro ao longo desse intervalo e o crescimento do PSR é expressivo: o número de apólices saltou de 75.728 em 2016 para 209.584 em 2021, refletindo a expansão do programa e o aumento da demanda por cobertura agrícola subsidiada. A partir de 2022, o volume recua para patamares entre 101.104 e 136.194 apólices anuais, movimento que pode ser atribuído, por exemplo, a ajustes no orçamento federal de subvenção e a mudanças nas regras de habilitação de seguradoras participantes. Adicionalmente, o comportamento da taxa de sinistro ao longo do período revela um padrão de alta volatilidade, característico do risco agrícola sistêmico discutido por Mota, Miquelluti e Ozaki (2020). A taxa permaneceu em patamares inferiores a 20% entre 2016 e 2020, com exceção do ano de 2018, refletindo condições climáticas relativamente favoráveis. O ano de 2021, por outro lado, registra o maior patamar do período, com taxa superior a 50%, resultado consistente com os efeitos do fenômeno La Niña sobre a produção agrícola nas regiões de maior concentração do PSR (Mota; Miquelluti; Ozaki, 2020).

Figura 6 - Evolução do volume de apólices e taxa de sinistro (2016-2025)




Fonte: elaboração própria. Fonte dos Dados: BRASIL (2026)

A Figura 7 apresenta a distribuição geográfica das apólices e as taxas de sinistro por macrorregião brasileira. Nessa perspectiva, nota-se que a concentração na Região Sul é dominante, sendo responsável por 709.012 apólices, equivalentes a 65% da base total. As

regiões Sudeste e Centro-Oeste somam, respectivamente, 232.781 e 126.994 contratos, ao passo que, Nordeste e Norte representam, juntas, pouco mais de 2% das apólices. Além disso, a análise da taxa de sinistro por região revela que a Região Sul apresenta o maior índice (30,4%), seguida pelo Centro-Oeste (27,0%) e Sudeste (20,3%), com Nordeste e Norte empatados em 20,2%. Esse padrão de concentração no eixo Sul do Brasil também é documentado na literatura: Mota, Miquelluti e Ozaki (2020) identificaram que a região concentra mais de 80% dos eventos de sinistros nas principais culturas.

A Figura 8 apresenta a distribuição dos contratos por tipo de cultura e as respectivas taxas de sinistro. A categoria grãos concentra 584.016 apólices (54% do total), confirmando a elevada representatividade de soja, milho e trigo no PSR, padrão documentado por Mota, Miquelluti e Ozaki (2020) e consistente com o perfil exportador do agronegócio brasileiro (MAPA, 2026). A segunda categoria em volume é “outros”, que agrupa cana-de-açúcar, pecuário, florestas e pastagem, com 264.234 contratos. Frutas e perenes respondem por 113.089 e 90.975 apólices, respectivamente, enquanto hortaliças, sementes e leguminosas somam cerca de 4% da base.


Figura 7 - Distribuição geográfica do PSR (2016-2025)



Fonte: elaboração própria. Fonte dos Dados: BRASIL (2026)

Além disso, a taxa de sinistro por categoria de cultura apresenta variação considerável em torno da média geral de 27,6%. Sementes registram o maior índice (39,6%), seguidas por leguminosas (35,5%) e outros (32,3%), ao passo que perenes e hortaliças representam as menores taxas, de 17,1% e 18,4%, respectivamente. Nesse sentido, a categoria de grãos, responsável pela maior fatia da carteira, situa-se em 28,2%, levemente acima da média.

Figura 8 - Concentração por tipo de cultura - PSR (2016-2025)



Fonte: elaboração própria. Fonte dos Dados: BRASIL (2026)

Os resultados descritivos desta seção fornecem o contexto interpretativo para as que se seguem. A concentração de 65% dos contratos na Região Sul, com sinistralidade de 30,4%, explica por que as variáveis de risco por cultura e UF emergem como o segundo grupo mais relevante na análise de importância da Seção 4.4. A volatilidade interanual da sinistralidade, com taxas abaixo de 20% entre 2016 e 2020 e acima de 50% em 2021, antecipa diretamente o peso de 36% que a dimensão temporal assumirá nessa mesma seção. A taxa média de 27,6%, por fim, define a linha de base aleatória que dá escala à AUC-PR de 0,794 reportada na Seção 4.3: um modelo sem poder preditivo obteria precisão média equivalente à proporção de sinistros na amostra, ao passo que o modelo campeão sustenta quase três vezes esse valor.

4.2 COMPARATIVO DOS MODELOS

O processo de seleção do modelo preditivo seguiu a estratégia descrita na Seção 3.4. Assim, procedeu-se à avaliação de quatro algoritmos como *baselines*, seguida de ajuste de hiperparâmetros via *GridSearchCV* com validação cruzada estratificada sobre o modelo campeão. A Tabela 3 apresenta o desempenho de cada algoritmo no conjunto de teste, ordenado pelo critério primário de seleção, a AUC-ROC.

Tabela 3 - Métricas *baseline* dos algoritmos

Modelo	Acurácia	AUC-ROC	AUC-PR	KS	Lift@10%
XGBoost	0,8002	0,8783	0,7685	0,5957	3,1054
Random Forest	0,7588	0,8434	0,7094	0,5295	2,8784
Árvore de Decisão	0,7239	0,8214	0,6568	0,4827	2,7904
AdaBoost	0,7594	0,7737	0,5959	0,4053	2,5592

Fonte: elaboração própria


O XGBoost obteve o melhor desempenho em todas as métricas avaliadas já na condição de baseline: AUC-ROC de 0,878, AUC-PR de 0,769, KS de 0,596 e Lift cumulativo a 10% de 3,105. Random Forest situou-se em segundo lugar, com AUC-ROC de 0,843, e a Árvore de Decisão em seguida, com um AUC-ROC de 0,821, resultado notável para um modelo de baixa complexidade. AdaBoost apresentou o desempenho mais fraco do conjunto, com um AUC-ROC de 0,774, indicando que o algoritmo, dentre os demais, não capturou tão bem as interações não lineares presentes nos dados.

4.3 AVALIAÇÃO DO MODELO CAMPEÃO

O modelo XGBoost ajustado foi avaliado em duas condições diferentes: seu desempenho sobre o mesmo conjunto de teste utilizado na seção 4.2, composto por 30% das apólices com ciclo encerrado anteriores ao corte de janeiro de 2025, e o comportamento dos escores gerados sobre o período *Out-of-Time* (OOT), composto por 40.345 apólices com data de início de vigência a partir de janeiro de 2025.


A Figura 9 apresenta a curva ROC do modelo campeão sobre o conjunto de teste. A área sob a curva atingiu 0,893, o que significa que, em aproximadamente 89,3% dos pares de apólices formados por um contrato com sinistro e outro sem sinistro, o modelo ordena corretamente o contrato de maior risco. Em termos comparativos, Mota, Miquelluti e Ozaki (2020), ao aplicarem Random Forest sobre os dados de PSR para o período de 2006 a 2017, obtiveram AUC de 0,63. Dessa forma, o modelo apresentado situa-se 26 pontos percentuais acima do melhor resultado reportado por tais autores sobre a mesma fonte de dados, refletindo o efeito combinado de três fatores: (i) a amplitude temporal da base de dados; (ii) a engenharia de atributos (*feature engineering*); e (iii) a capacidade do XGBoost de capturar interações não lineares entre os grupos de variáveis construídos na *Feature Store*.

Figura 9 - Curva ROC - conjunto de teste



Fonte: elaboração própria.


Além disso, a Figura 10 apresenta a curva *Precision-Recall* (PR). A precisão média (*Average Precision*) atingiu 0,794 contra uma linha de base aleatória de 27,6%, correspondente à taxa de sinistro da amostra. A curva evidencia que, mesmo ao configurar o modelo para capturar metade dos sinistros reais (*recall* de 50%), a precisão permanece em torno de 85%, isto é, 85 em cada 100 apólices sinalizadas pelo modelo correspondem de fato a contratos que resultaram em sinistro. Esse resultado indica que o modelo mantém alta precisão mesmo quando o limiar de decisão é ajustado para ampliar a cobertura de sinistros.

Figura 10 - Curva *Precision-Recall* - conjunto de teste

Fonte: elaboração própria.

A Figura 11, por sua vez, apresenta a distribuição dos escores preditos por classe. A separação entre as distribuições da classe negativa e positiva é notável, demonstrando que apólices sem sinistro concentram-se nos decis inferiores de probabilidade, ao passo que, apólices com sinistro acumulam densidade nos decis superiores. Assim, a estatística KS de 0,626 mede a máxima diferença absoluta entre as funções de distribuição acumulada das duas classes, indicando separação discriminatória substancial. Em termos operacionais, um KS nesse patamar significa que o modelo atribui escores distintos às duas classes (Rezac; Rezac, 2011).

Figura 11 - Distribuição dos escores preditos por classe



Fonte: elaboração própria.

Além disso, a análise do período OOT evidenciou uma característica importante da fonte de dados. Considerando o corte em 31 de dezembro de 2025, das 40.345 apólices com data de início de vigência a partir de janeiro de 2025, 17.135 (42,47%) apresentavam ciclo de vigência formalmente encerrado, ao passo que 23.210 (57,53%) ainda se encontravam em vigor. No entanto, a taxa de sinistro registrada no campo *evento* é zero para ambos os grupos, padrão incompatível com qualquer safra histórica da série e indicativo de defasagem administrativa na consolidação dos eventos pelo SISSER. Assim, essa constatação inviabiliza o cálculo de métricas supervisionadas sobre o período OOT, não por ausência de desfecho no mundo real, mas pela incompletude do registro na fonte de dados disponível.


4.4 IMPORTÂNCIA DAS VARIÁVEIS

A importância das variáveis foi calculada pelo ganho médio (*gain*), métrica disponível na documentação do XGBoost que representa a melhoria média de acurácia do modelo em

todas as divisões nas quais cada variável é utilizada (XGBoost, 2026). A análise desses valores permite identificar quais grupos de *features* contribuem de forma mais expressiva para a capacidade preditiva do modelo e discutir implicações para o mercado de seguro rural.

Desse modo, a Figura 12 apresenta as quinze variáveis de maior importância individual do modelo campeão. A variável *nrAnoPlantio* responde por 36,0% da importância total, valor expressivamente superior ao da segunda colocada, *nrConcentracaoSeguradora365d*, com 4,5%. Assim, observa-se que o ano de plantio captura as variações na taxa de sinistro entre as safras. Como evidenciado na Seção 4.1, durante o período de treinamento, a sinistralidade apresentou alta volatilidade entre os anos, com taxas inferiores a 20% nos anos de 2016 a 2020 e superiores a 50% em 2021. O modelo aprendeu, portanto, a associar determinados períodos a níveis de risco historicamente distintos. Em produção, no entanto, essa variável refere-se a anos futuros sem histórico de treinamento, limitando, assim, a generalização desse componente. As demais variáveis, cujas contribuições representam aproximadamente 64% da importância total, são o foco da discussão a seguir.

Figura 12 - Top 15 variáveis por importância - modelo campeão




Fonte: elaboração própria.

A Figura 13 consolida a importância por grupo de variáveis. O grupo de risco por cultura e UF responde por 24,2% da importância agregada, sendo o mais relevante após a dimensão temporal. Variáveis como *nrTaxaSinistroCulturaUf730d* e *nrStdTaxaCulturaUf365d* indicam que o modelo encontrou capacidade explicativa no comportamento histórico da combinação cultura-estado, padrão coerente com a persistência geográfica e agrônômica da sinistralidade documentada por Mota, Miquelluti e Ozaki (2020).

O grupo “Outros” contribui com 12,9%, composto pelas variáveis categóricas *tipo_cultura* (3,5%), *seguradora* (2,6%) e *regiao* (2%), além das codificações cíclicas do mês do plantio (*nrSinMes* e *nrCosMes*), o que indica que a identidade da cultura, da operadora e da macrorregião carregam informação complementar não inteiramente capturada pelas agregações históricas. Além disso, o grupo histórico por município contribui com 10,7%, e o grupo de risco por seguradora com 9,8%, destacando-se *nrConcentracaoSeguradora365d*. Seguradoras com alta participação em nichos cultura-território específicos tendem a apresentar carteiras menos diversificadas e mais expostas a choques sistêmicos, resultado consistente com os efeitos do índice HHI discutidos por Ávila et al. (2013). Por fim, os grupos de variáveis financeiras da apólice (3,9%) e de anomalia de precificação (2,1%) complementam as informações utilizadas pelo modelo na inferência.

Figura 13 - Importância por grupo de variáveis



Fonte: elaboração própria.

5 CONSIDERAÇÕES FINAIS

O presente estudo se dedicou a explorar o problema de predição de sinistros no PSR como uma classificação binária supervisionada, aplicada sobre 1.094.697 apólices da base SISSER cobrindo o período de 2016 a 2025. A solução combinou uma arquitetura de processamento em camadas progressivas de qualidade, uma *Feature Store* com semântica *point-in-time* em seis tabelas de agregação histórica e validação *out-of-time* com corte em janeiro de 2025, reproduzindo as condições reais de operação de um modelo preditivo.

Entre os quatro algoritmos avaliados, o XGBoost obteve o melhor desempenho em todas as métricas, com AUC-ROC de 0,893, AUC-PR de 0,794, KS de 0,626 e Lift cumulativo a 10% de 3,195. O AUC-ROC supera em 26 pontos percentuais o melhor resultado reportado por Mota, Miquelluti e Ozaki (2020) sobre a mesma fonte de dados. Esse ganho de desempenho não decorre de um único fator: a granularidade das *features* construídas em nível de apólice individual, a amplitude temporal da base e o tratamento do desbalanceamento de classes atuam de forma conjunta.

Duas limitações condicionam a interpretação dos resultados. A variável *nrAnoPlantio* respondeu por 36,0% da importância total, valor notoriamente superior ao de qualquer outro preditor. Esse peso, por sua vez, reflete a volatilidade interanual da sinistralidade no período de treinamento, com taxas inferiores a 20% entre 2016 e 2020 e superiores a 50% em 2021, padrão associado a choques climáticos como o La Niña. Em produção, a variável refere-se a anos futuros sem histórico de treinamento, o que limita a generalização do componente temporal. A segunda limitação diz respeito à validação *out-of-time*: dos 40.345 contratos do período OOT, 17.135 (42,47%) apresentavam ciclo de vigência formalmente encerrado e 23.210 (57,53%) ainda se encontravam em vigor, mas o campo *evento* indicava ausência de sinistro para a totalidade dos casos em ambos os grupos. Esse padrão é incompatível com qualquer safra histórica e, assim, é um possível indicador de defasagem administrativa na consolidação dos eventos junto ao SISSER, inviabilizando, portanto, o cálculo de métricas supervisionadas sobre o período mais recente.

Para pesquisas futuras, quatro direções se destacam. A exclusão de *nrAnoPlantio* do conjunto de treinamento e a reavaliação do desempenho permitiriam quantificar em que medida os demais grupos de variáveis sustentam a capacidade discriminatória do modelo, separando a contribuição da engenharia de variáveis históricas da dependência temporal aprendida durante o treinamento. Como segundo ponto, a incorporação de variáveis climáticas externas, como índices ENOS e precipitação acumulada no ciclo vegetativo por

município, representa o caminho promissor para reduzir essa dependência do componente temporal identificada como limitação do modelo atual. Além disso, a ampliação da granularidade dos dados para o nível de propriedade rural, caso microdados georreferenciados sejam disponibilizados, permitiria superar a agregação municipal e aproximar as variáveis do risco efetivo de cada operação. Por fim, a extensão do problema para a modelagem de severidade, com estimação do valor esperado de indenização condicionado à ocorrência de sinistro, completaria a capacidade preditiva do modelo com a estimativa do custo esperado por apólice, além de ser uma informação utilizada no cálculo de provisões técnicas.

REFERÊNCIAS

- ÁVILA, F. et al. Concentration indicators: assessing the gap between aggregate and detailed data. **Bank for International Settlements**, v. 36, p. 542-559, 2013
- BRASIL. **Agropecuária brasileira em números**. Brasília, DF: Ministério da Agricultura, Pecuária e Abastecimento (MAPA), 2026. 15 p.
- BRASIL. **Sistema de Subvenção Econômica ao Prêmio do Seguro Rural - SISSER - PSR - 2016 a 2025 - Portal de Dados Abertos do Ministério da Agricultura e Pecuária**, 2026. Disponível em: [Link](#). Acesso em: 26 abr. 2026.
- BÄRTL, M.; KRUMMAKER, S. Prediction of claims in export credit finance: a comparison of four machine learning techniques. **Risks**, v. 8, n. 1, p. 22, 2020.
- BREIMAN, L. Random Forests. **Machine Learning**, v. 45, n.1, p. 5-32, 2001.
- CHEN, T.; GUESTRIN, C. XGBoost: a Scalable Tree Boosting System. **Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining - KDD '16**, v. 1, n. 1, p. 785–794, 2016.
- DATABRICKS. Databricks Documentation. **Databricks Documentation**, 2026a. Disponível em: [Link](#). Acesso em: 14 abr. 2026
- DATABRICKS. What is medallion architecture? **Databricks Documentation**, 2026b. Disponível em: [Link](#). Acesso em: 14 abr. 2026
- DATABRICKS. Point-in-time feature joins. **Databricks Documentation**, 2026c. Disponível em: [Link](#). Acesso em: 14 abr. 2026
- DREISEITL, S.; OHNO-MACHADO, L. Logistic regression and artificial neural network classification models: a methodology review. **Journal of Biomedical Informatics**, v. 35, n. 5–6, 2002.
- EJIYI, C. J. et al. Comparative analysis of building insurance prediction using some machine learning algorithms. **International Journal of Interactive Multimedia and Artificial Intelligence**, v. 7, n. 3, p. 75, 2022.
- FAWCETT, T. An introduction to ROC analysis. **Pattern Recognition Letters**, v. 27, n. 8, p. 861–874, 2006.
- FREUND, Y; SCHAPIRE, R. E. A decision-theoretic generalization of on-line learning and an application to boosting. **Journal of Computer and System Sciences**, v. 55, n. 1, p. 119–139, 1997.
- HUYEN, Chip. **Designing Machine Learning Systems: An Iterative Process for Production-Ready Applications**. Sebastopol: O'Reilly Media, 2022.
- MAHESH, B. Machine learning algorithms: a review. **International Journal of Science and Research (IJSR)**, v. 9, 2019.

MATSUMOTO, S. Understand the capabilities of cyclic encoding: it's not only represent cyclic proximity, but also represent every waveforms. **Medium**, 2023. Disponível em: [Link](#). Acesso em: 16 abr. 2026.

MENARDI, G.; TORELLI, N. Training and assessing classification rules with imbalanced data. **Data Mining and Knowledge Discovery**, v. 28, n. 1, p. 92–122, 2014.

MOTA, A. L.; MIQUELLUTI, D. L.; OZAKI, V. A. Predição de sinistros agrícolas: uma abordagem comparativa utilizando aprendizagem de máquina. **Economia Aplicada**, v. 24, n. 4, p. 533-554, 2020.

OZAKI, V. A. Em busca de um novo paradigma para o seguro rural no Brasil. **Revista de Economia e Sociologia Rural**, v. 46, n. 1, p. 97–119, 2008.

PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, p. 2825–2830, 2011.

PIJL, T. A framework to forecast insurance claims. **Econometrie**, 2017.

PYTHON. **The Python Programming Language**. 2026. Disponível em: [Link](#). Acesso em: 02 mai. 2026.

REZAC, M.; REZAC, F. How to Measure the Quality of Credit Scoring Models. **Finance a uver: Czech Journal of Economics and Finance**, v. 61, n. 5, p. 486–507, 2011.

SCULLEY, D. et al. Hidden technical debt in machine learning systems. **Neural Information Processing Systems**, v. 28, p. 2503–2511, 2015.

XGBOOST. **XGBoost Documentation**. Disponível em: [Link](#). Acesso em: 14 abr. 2026

WEISS, G. M.; MCCARTHY, K.; ZABAR, B. Cost-sensitive learning vs. sampling: which is best for handling unbalanced classes with unequal error costs? **DMIN**, p. 35–41, 2007.

ZAHARIA, M. et al. Accelerating the machine learning lifecycle with MLflow. **IEEE Data Engineering Bulletin**, v. 41, n. 4, p. 39–45, 2018.

ZAHARIA, M. et al. Apache Spark: a Unified Engine for Big Data Processing. **Communications of the ACM**, v. 59, n. 11, p. 56–65, 2016.